

Clasificación Astronómica con Inteligencia Artificial

Un Enfoque de Machine Learning para Descubrir los Secretos del Cosmos



Evaluación Comparativa de Modelos para Identificar Galaxias, Estrellas y Cuásares en el Sloan Digital Sky Survey

En la era de la astronomía de grandes volúmenes de datos, proyectos como el *Sloan Digital Sky Survey* generan información masiva que desafía los métodos tradicionales de análisis. Este informe explora cómo tres poderosos algoritmos de *Machine Learning* —Regresión Logística, KNN y Random Forest— pueden automatizar y optimizar la clasificación de estrellas, galaxias y cuásares con una precisión asombrosa.

Imagina intentar clasificar a mano millones de estrellas, galaxias y cuásares en un océano de datos astronómicos. Ahora piensa en un sistema que puede hacerlo en segundos, con una precisión casi perfecta. En un universo donde cada noche los telescopios capturan terabytes de información, la inteligencia artificial se ha convertido en el nuevo telescopio digital de los astrónomos.

Este informe no es solo sobre algoritmos; es sobre cómo el *machine learning* está redefiniendo nuestra capacidad para descifrar el cosmos. ¿Sabías que incluso los objetos más esquivos, como los cuásares —los faros brillantes de agujeros negros supermasivos—, pueden ser identificados automáticamente con un 99% de certeza? Aquí exploramos cómo tres modelos compitieron por el título del "mejor clasificador astronómico", revelando no solo qué técnica ganó, sino también *por qué sus resultados son cruciales para futuros descubrimientos*.

Desde acelerar la búsqueda de galaxias raras hasta filtrar datos para estudios de energía oscura, estos algoritmos no solo procesan números: **están ampliando los límites de lo que podemos descubrir**. Si alguna vez te preguntaste cómo la ciencia maneja la avalancha de datos del espacio, este informe te lleva tras bambalinas de la revolución que está transformando la astronomía moderna. 🚀

Spoiler Alert: La respuesta está en los árboles... pero no son los que creces.

Analicemos el desempeño de tres modelos de machine learning (Regresión Logística, KNN y Random Forest) para clasificar objetos astronómicos en tres categorías: galaxias (GALAXY), cuásares (QSO) y estrellas (STAR). Los resultados demuestran que el modelo Random Forest obtuvo el mejor rendimiento general con un accuracy del 99%, seguido por Regresión Logística (98%) y KNN (97%). El análisis detallado de las métricas y gráficos del mejor modelo (Random Forest) revela una excelente capacidad de clasificación, particularmente útil para la comunidad astronómica en la automatización de procesos de catalogación.

Evaluación Comparativa: ¿Cómo le Fue a Cada Modelo?

Regresión Logística: El Clásico Confiable

La Regresión Logística, es el método estadístico de toda la vida, demostró que todavía tiene mucho que ofrecer. Con un 98% de precisión general, se defendió muy bien, especialmente con galaxias, donde casi no cometió errores. Sin embargo, tuvo un pequeño tropiezo con los cuásares (QSO), confundiendo algunos con galaxias. Parece que, aunque es sólido, le cuesta un poco cuando los objetos tienen características intermedias.

Categoría	Precisión	Recall	F1-score	Soporte
GALAXY	0.98	0.98	0.98	1128
QSO	0.98	0.87	0.92	201
STAR	0.98	1.00	0.99	671
Exactitud Total			0.98	2000
Media Macro	0.98	0.95	0.96	2000
Media Ponderada	0.98	0.98	0.98	2000

KNN: El Vecino que Acierta... Casi Siempre

K-Nearest Neighbors, el modelo que clasifica basándose en "lo que hay alrededor", logró un respetable 97% de aciertos. Fue consistente en todas las categorías, pero al igual que la


Regresión Logística, tuvo sus dificultades con los cuásares, dejando escapar un 10% de ellos (clasificándolos mal como galaxias). Aunque es rápido y sencillo, su dependencia de los datos cercanos lo hace un poco menos preciso cuando las clases se solapan.

Categoría	Precisión	Recall	F1-score	Soporte
GALAXY	0.97	0.98	0.97	1128
QSO	0.98	0.90	0.94	201
STAR	0.96	0.97	0.96	671
Exactitud Total			0.97	2000
Media Macro	0.97	0.95	0.96	
Media Ponderada	0.97	0.97	0.97	

Random Forest: El Ganador Incontestable

¡Y aquí está el campeón! **Random Forest no solo alcanzó un 99% de precisión, sino que prácticamente no falló en estrellas y galaxias.** Los cuásares, esos objetos escurridizos, fueron los únicos que le dieron un poco de trabajo, pero aún así logró un **93% de recall** (solo un puñado se le escaparon). Lo más impresionante es su **capacidad para distinguir patrones complejos** en los datos, gracias a su estructura de "bosque de decisiones". Si hubiera un Oscar para modelos de clasificación astronómica, Random Forest se lo llevaría sin duda.

Categoría	Precisión	Recall	F1-score	Soporte
GALAXY	0.99	1.00	0.99	1128
QSO	0.99	0.93	0.96	201
STAR	1.00	1.00	1.00	671
Exactitud Total			0.99	2000
Media Macro	0.99	0.98	0.98	
Media Ponderada	0.99	0.99	0.99	



El modelo RandomForest obtuvo el mejor desempeño en términos de accuracy (99.10%), seguido por LogisticRegression (97.80%) y KNN (96.55%). Esto indica que RandomForest tiene la mayor capacidad para clasificar correctamente las instancias entre todas las categorías.

Mientras que en la métrica Macro F1-Score, que considera el balance entre precisión y recall para todas las clases, RandomForest nuevamente lidera (0.983), con LogisticRegression (0.964) y KNN (0.957) mostrando valores ligeramente inferiores pero aún competitivos.

Modelo	Accuracy	Macro F1-Score	n_PCA
RandomForest	0.9910	0.983181	NaN
LogisticRegression	0.9780	0.963631	6.0
KNN	0.9655	0.957486	6.0

Es notable que tanto LogisticRegression como KNN utilizaron reducción de dimensionalidad con PCA (6 componentes principales), mientras que RandomForest no requirió esta técnica previa, lo que sugiere que este último modelo puede manejar bien datos de alta dimensionalidad sin necesidad de reducción previa.


¿Por Qué Importa Esta Competencia?

No se trata solo de qué modelo tiene el número más alto, sino de **entender sus fortalezas y debilidades en un contexto real**. Mientras la Regresión Logística es rápida y simple, y KNN es intuitivo, **Random Forest combinó precisión y robustez**, demostrando ser la mejor herramienta para tareas astronómicas donde un error mínimo puede marcar la diferencia entre descubrir un nuevo cuásar o perderlo en el ruido de los datos.

Análisis Detallado del Modelo Random Forest

Importancia de Variables y Comportamiento del Modelo

El análisis de importancia de variables en el Random Forest revela patrones consistentes con los principios astronómicos:




Dominio de las magnitudes fotométricas: Las bandas r, i y g emergen como las características más determinantes, seguida de los índices de color u-g y g-r. Esto refleja cómo los diferentes objetos celestes tienen firmas espectrales características en estas longitudes de onda.

Redshift como variable secundaria: Aunque contribuye al modelo, su menor importancia relativa sugiere que las propiedades fotométricas por sí solas ya capturan gran parte de la información discriminativa.

Matriz de Confusión: Excelencia con Errores Interpretables

La matriz de confusión detalla un desempeño excepcional pero con errores comprensibles:

- **Clasificación casi perfecta para estrellas:** Las 671 estrellas en el conjunto de prueba fueron identificadas correctamente, reflejando que sus firmas fotométricas son altamente distintivas.
- **Intercambio galaxia-QSO:** Los 14 QSO mal clasificados como galaxias representan casos límite donde cuásares con galaxias anfitrionas prominentes pueden mostrar características intermedias. Este 7% de error en QSO coincide con lo esperado en observaciones astronómicas reales.
- **Precisión galáctica del 99.8%:** Solo 2 de 1126 galaxias fueron mal clasificadas, demostrando que el modelo captura excelentemente sus propiedades fotométricas típicas.




Curvas ROC: Validación del Poder Discriminativo

Las curvas ROC confirman la robustez del modelo en todos los tipos de objetos:

- **Clasificación perfecta para estrellas y galaxias:** Los AUC de 1.00 indican separabilidad completa, sin solapamiento en sus características.
- **Excepcional desempeño con QSOs:** El AUC de 0.99, aunque ligeramente inferior, sigue mostrando una capacidad discriminativa casi perfecta, con las curvas ubicadas muy cerca del ángulo superior izquierdo.

- **Consistencia con métricas previas:** Estos resultados validan los altos valores de accuracy y F1-score reportados inicialmente, demostrando que el buen desempeño no es artefacto de desbalance de clases.



Impacto para la Comunidad

Este sistema de clasificación automatizada representa un avance en el procesamiento de datos astronómicos modernos. Al poder analizar miles de objetos por segundo, multiplica la eficiencia en el estudio de grandes *surveys* como el SDSS, transformando lo que antes requería meses de trabajo manual en cuestión de horas. Pero más allá de la velocidad, su verdadero valor radica en la consistencia que aporta: elimina la subjetividad inherente a las clasificaciones humanas, donde criterios individuales o condiciones de observación podían introducir sesgos.

Un aspecto particularmente valioso es su capacidad para identificar automáticamente objetos con clasificaciones inciertas. Estos casos límite, que el modelo marca como "dudosos", no son errores del sistema, sino oportunidades científicas. Muchos descubrimientos astronómicos provienen precisamente de anomalías o clasificaciones ambiguas, y ahora el modelo puede señalarlas sistemáticamente para su estudio detallado. Esto es especialmente relevante para los cuásares (QSOs), objetos complejos cuya precisa identificación abre puertas a investigaciones sobre agujeros negros supermasivos, la estructura a gran escala del universo y la evolución cósmica.

La escalabilidad del sistema lo hace futuro-proof. Con la próxima generación de instrumentos como el LSST o Euclid, que generarán volúmenes de datos sin precedentes, este enfoque demostró ser técnicamente viable. El modelo Random Forest, con su combinación de precisión (99.1% accuracy) y capacidad para manejar datos de alta dimensionalidad sin

requerir preprocesamiento complejo, se posiciona como la solución óptima para implementación inmediata en los *pipelines* de análisis.

Sin embargo, el trabajo no termina aquí. Para maximizar su impacto, recomendamos: implementar un sistema de monitoreo continuo que evalúe el modelo con nuevos datos, explorar arquitecturas de *deep learning* que puedan capturar relaciones no lineales aún más complejas, y desarrollar interfaces intuitivas que permitan a astrónomos sin expertise en machine learning aprovechar esta herramienta. Este proyecto no solo resuelve un problema técnico, sino que redefine cómo la comunidad astronómica puede interactuar con los datos masivos, liberando tiempo valioso para la interpretación científica y el descubrimiento, en lugar de tareas rutinarias de clasificación.